Laporan Tugas Besar 2 IF3170 Inteligensi Artifisial

Implementasi Algoritma Pembelajaran Mesin

Kelompok AIKamuMah:

Andi Farhan Hidayat	13523128
Ahmad Syafiq	13523135
Andri Nurdianto	13523145
Rafael Marchel D. W.	13523146
Muhammad Kinan Arkansyaddad	13523152

Teknik Informatika

Institut Teknologi Bandung

Daftar Isi

1. Implementasi Decision Tree Learning

Decision Tree adalah model supervised learning yang memprediksi label kelas dengan membangun struktur pohon keputusan berdasarkan fitur-fitur input. Setiap node internal merepresentasikan tes pada sebuah fitur, cabang merepresentasikan hasil dari tes tersebut, dan setiap leaf node merepresentasikan label kelas prediksi. Decision tree bekerja dengan membagi data secara rekursif berdasarkan fitur yang memberikan pemisahan terbaik.

Implementasi Decision Tree Learning mendukung tiga algoritma splitting yang dapat dipilih melalui parameter *algorithm*:

A. ID3 (Information Gain)

Algoritma ini menggunakan Entropy sebagai ukuran ketidakmurnian (impurity). Entropy mengukur tingkat ketidakteraturan dalam kumpulan data:

$$H(S) = -\sum_{i=1}^{c} p_i \log_2(p_i)$$

Dengan p_i adalah proporsi sampel kelas i dalam dataset S, dan c adalah jumlah kelas.

Information Gain mengukur pengurangan entropy setelah melakukan split:

$$IG(S, A) = H(S) - \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} H(S_v)$$

Fitur dengan Information Gain tertinggi dipilih untuk split.

B. C4.5 (Gain Ratio)

Algoritma C4.5 menggunakan Gain Ratio untuk mengatasi bias Information Gain terhadap fitur dengan banyak nilai unik. Gain Ratio menormalisasi Information Gain dengan Split Information:

$$\text{SplitInfo}(S, A) = -\sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} \log_2 \left(\frac{|S_v|}{|S|} \right)$$

$$\text{GainRatio}(S, A) = \frac{IG(S, A)}{\text{SplitInfo}(S, A)}$$

Pendekatan ini memberikan preferensi yang lebih seimbang terhadap fitur dengan jumlah kategori yang moderat.

C. CART (Gini Index)

CART menggunakan Gini Impurity sebagai ukuran ketidakmurnian:

$$\text{Gini}(S) = 1 - \sum_{i=1}^{c} p_i^2$$

Gini Gain dihitung sebagai pengurangan Gini impurity setelah split:

$$\text{GiniGain}(S, A) = \text{Gini}(S) - \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} \text{Gini}(S_v)$$

Gini Index cenderung lebih efisien secara komputasi karena tidak menggunakan operasi logaritma.

Implementasi DTL menangani missing values dengan strategi majority branch assignment. Saat training:

- Hanya sampel dengan nilai fitur yang diketahui yang digunakan untuk menghitung gain.
- Sampel dengan missing values diarahkan ke cabang yang memiliki sampel lebih banyak (*majority branch*).

Saat prediksi, jika value fitur missing, observasi diarahkan ke cabang yang sama dengan yang digunakan saat training (*left_branch_majority*).

Untuk mencegah *overfitting*, kami mengimplementasikan Cost-Complexity Pruning (CCP), juga dikenal sebagai weakest link pruning. Metode ini menambahkan penalti kompleksitas ke fungsi cost:

$$R_\alpha(T) = R(T) + \alpha|T|$$

Pendekatan ini memastikan tree yang dihasilkan memiliki keseimbangan optimal antara akurasi dan generalisasi sesuai dengan nilai *ccp_alpha* yang ditentukan.

2. Implementasi Logistic Regression

Logistic Regression adalah model statistik yang digunakan untuk memprediksi probabilitas kejadian suatu kelas biner. Berbeda dengan regresi linear yang memprediksi nilai kontinu, Logistic Regression memetakan keluaran linear ke dalam rentang probabilitas [0,1] menggunakan fungsi Sigmoid (atau Logistik).

Secara matematis, untuk sebuah sampel data x dengan bobot w dan bias b, skor linear z dihitung sebagai:

$$z = w^T x + b$$

Skor ini kemudian dipetakan menjadi probabilitas $\hat{y}$ menggunakan fungsi Simoid:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Jika nilai $\hat{y} \geq 0.5$, sampel diklasifikasikan ke dalam kelas positif (1), dan sebaliknya ke kelas negatif (0).

Dataset yang digunakan memiliki variabel target dengan tiga kategori (Dropout, Enrolled, Graduate). Karena Logistic Regression standar hanya bekerja pada klasifikasi biner, kami mengimplementasikan dua strategi untuk menangani masalah multikelas ini, yaitu One-vs-Rest (OvR) dan Multinomial (Softmax) Regression.

Strategi One-vs-Rest atau One-vs-All memecah masalah klasifikasi K kelas menjadi K masalah klasifikasi biner yang independen. Pendekatan ini dipilih berdasarkan studi oleh Rifkin & Klautau (2004) yang menyatakan bahwa skema ini memiliki akurasi yang setara dengan pendekatan multikelas lainnya jika pengklasifikasi biner dasarnya dioptimasi dengan baik. Rifkin & Klautau (2004) juga menyimpulkan bahwa One-vs-Rest sebaiknya menjadi pendekatan untuk klasifikasi

multikelas karena kesederhanaan konseptual dan kemudahan implementasinya dibandingkan metode yang lebih kompleks. Dalam implementasi kami pada metode *_fit_ovr*:

1. Model melatih K = 3 klasifier biner secara terpisah
2. Untuk setiap kelas target (misalnya Dropout), label data diubah menjadi biner: 1 untuk Dropout dan 0 untuk sisanya (Enrolled dan Graduate).
3. Setiap model memiliki parameter bobot w dan bias b masing-masing.

Untuk melatih model, kami menggunakan algoritma Stochastic Gradient Ascent (SGA) sesuai yang diajarkan di perkuliahan. Tujuan optimasi adalah memaksimalkan Log-Likelihood (setara meminimalkan Log-Loss).

Langkah algoritma:

1. Inisialisasi bobot w dan bias b dengan 0.
2. Lakukan iterasi sebanyak T epoch (iterasi).
3. Pada setiap epoch, urutan data diacak untuk menjamin sifat stokastik.
4. Pembaruan bobot setiap iterasi data:

$$w \leftarrow w + \eta \cdot (y^{(i)} - p^{(i)}) \cdot x^{(i)}$$

Untuk melakukan prediksi, input $\boldsymbol{x}$ dimasukkan ke dalam ketiga model tersebut. Kelas prediksi diambil berdasarkan model yang memberikan probabilitas tertinggi (*argmax*):

$$\hat{y} = \arg \max_{k \in \{1,\ldots,K\}} \left(\sigma(w_k^T x + b_k)\right)$$

Sebagai alternatif, kami juga mengimplementasikan strategi Multinomial (Softmax) pada metode *_fit_softmax*. Berbeda dengan OvR yang melatih model secara terpisah, strategi ini melatih satu model gabungan yang memprediksi distribusi probabilitas untuk seluruh kelas sekaligus.

Fungsi Sigmoid digantikan oleh fungsi Softmax, yang menjamin bahwa total probabilitas seluruh kelas berjumlah 1. Fungsi Softmax adalah generalisasi dari fungsi Sigmoid untuk kasus multikelas target, yang

memetakan vektor skor linear z menjadi distribusi probabilitas yang valid (total probabilitas = 1).

$$P(y = k|x) = \frac{e^{z_k}}{\sum_{j=1}^{K} e^{z_j}}$$

Implementasi kami menerapkan teknik shift-invariance

$$\text{Softmax}(z)_k = \frac{e^{z_k - \max(z)}}{\sum_{j=1}^{K} e^{z_j - \max(z)}}$$

untuk mencegah numerical overflow saat menghitung eksponensial dari nilai fitur yang besar. Pembuktian bahwa fungsi Softmax dengan shift-invariance ekuivalen dengan fungsi Softmax dapat dilihat di sini: https://blester125.com/blog/softmax.html

Secara algoritmik, proses pelatihan ini juga dilakukan menggunakan Stochastic Gradient Ascent dengan langkah-langkah sebagai berikut:

1. Pada setiap iterasi, satu sampel (x,y) diambil secara acak dari dataset untuk menjamin sifat stokastik.
2. Label kategori y dikonversi menjadi vektor one-hot encoding (y_{onehot}) untuk memfasilitasi perhitungan error terhadap distribusi probabilitas.
3. Model menghitung prediksi probabilitas p menggunakan fungsi Softmax.
4. Gradien error dihitung sebagai selisih antara label one-hot asli dan probabilitas prediksi (error=y_{onehot}-p).
5. Matriks bobot W diperbarui menggunakan hasil outer product antara vektor input x dan vektor error, dikalikan dengan learning rate η.

Untuk mencegah overfitting, kami menerapkan regularisasi L1 dan L2 yang menambahkan term penalti pada fungsi objektif untuk membatasi kompleksitas model. L2 Regularization (Ridge) menambahkan penalti berupa kuadrat magnitudo bobot ke fungsi loss utama. Hal ini mendorong bobot agar tetap kecil tetapi tidak nol.

$$w \leftarrow w + \eta \left(\text{Error} \cdot x - \alpha w \right)$$

L1 Regularization menambahkan penalti berupa jumlah nilai absolut bobot ke fungsi loss. Berbeda dengan L2, L1 cenderung menghasilkan

solusi yang sparse, banyak bobot didorong menjadi tepat nol. Hal ini sangat berguna sebagai metode *feature selection* karena model akan "mematikan" fitur yang tidak relevan.

$$w \leftarrow w + \eta \left(\text{Error} \cdot x - \alpha \cdot \text{sign}(w) \right)$$

3. Implementasi SVM

Support Vector Machine (SVM) adalah salah satu algoritma *machine learning*. SVM memanfaatkan *hyperplane* sebagai metode klasifikasinya. Titik-titik data dari kelas dipisahkan oleh *hyperplane* pada ruang dimensi N. *Hyperplane* dicari dengan memaksimalkan margin dari 2 titik terdekat dengan kelas yang berbeda. Dua titik terdekat yang memiliki kelas berbeda disebut sebagai *support vectors* (vektor pendukung).

Secara mateatis, bidang pemisah ditulis sebagai:

$$w \cdot x + b = 0 \text{ (hyperplane optimal)}$$

$$w \cdot x + b = 1 \text{ (batas margin untuk kelas 1)}$$

$$w \cdot x + b = -1 \text{ (batas margin untuk kelas -1)}$$

Lalu, untuk menentukan kelas dari titik baru dituliskan sebagai berikut:

$$f(x) = w \cdot x + b$$

$$f(x) > 0 \text{ (titik masuk ke kelas 1)}$$

$$f(x) < 0 \text{ (titik masuk ke kelas -1)}$$

Dataset yang digunakan memiliki variabel target dengan tiga kategori (Dropout, Enrolled, Graduate). Dalam hal ini, strategi *one-vs-all* digunakan karena proses perbandingan hanya dilakukan sebanyak n kali sesuai dengan jumlah kelas yang ada sesuai yang ditulis oleh.

Untuk implementasi, kami terlebih dahulu hal-hal sebagai berikut dalam fungsi fit:

1. Model melatih K=3 *classifier* berbeda
2. Untuk setiap kelas target (misal Dropout), label bernilai 1 jika label yang dicek sesuai dengan kelas saat ini dan menjadi -1 jika label tidak sesuai dengan kelas saat ini (selain Dropout)
3. Model memiliki parameter bobot **w** dan bias b

Langkah-langkah penyelesaian algoritma SVM dengan menggunakan *one-vs-all* dijabarkan sebagai berikut:

1. Inisiasi bobot w dan b dengan nilai 0
2. Lakukan iterasi sebanyak n_iters epoch (iterasi).
3. Pengecekan fitur menggunakan $f(x) = w \cdot x + b$ dan memeriksa margin hasil perhitungan.
4. Pembaruan bobot. Jika kondisi margin terpenuhi, w diubah. Jika kondisi margin tidak terpenuhi, w dan b diubah.

4. Cleaning dan Preprocessing

Untuk mendapatkan hasil prediksi yang optimal, dataset perlu disiapkan dengan melakukan *data cleaning* dan *preprocessing*.

4.1. Data Cleaning

Data cleaning atau pembersihan data adalah proses penting dalam siklus analisis data untuk memastikan data yang digunakan akurat, konsisten, dan relevan. Data yang belum dibersihkan dapat menyebabkan kesalahan dalam analisis dan modeling, mengurangi keakuratan hasil, dan berdampak buruk pada pengambilan keputusan. Proses ini mencakup identifikasi, penanganan, dan penghapusan data yang tidak valid, duplikat, tidak lengkap, atau tidak relevan.

Pertama, dilakukan identifikasi *missing data*, *duplicate data,* dan *outlier*. Berdasarkan hasil yang didapat, ditemukan bahwa tidak ada *missing* ataupun *duplicate data*, namun terdapat *data outlier* dan beberapa kolom memiliki *skewness* yang tinggi

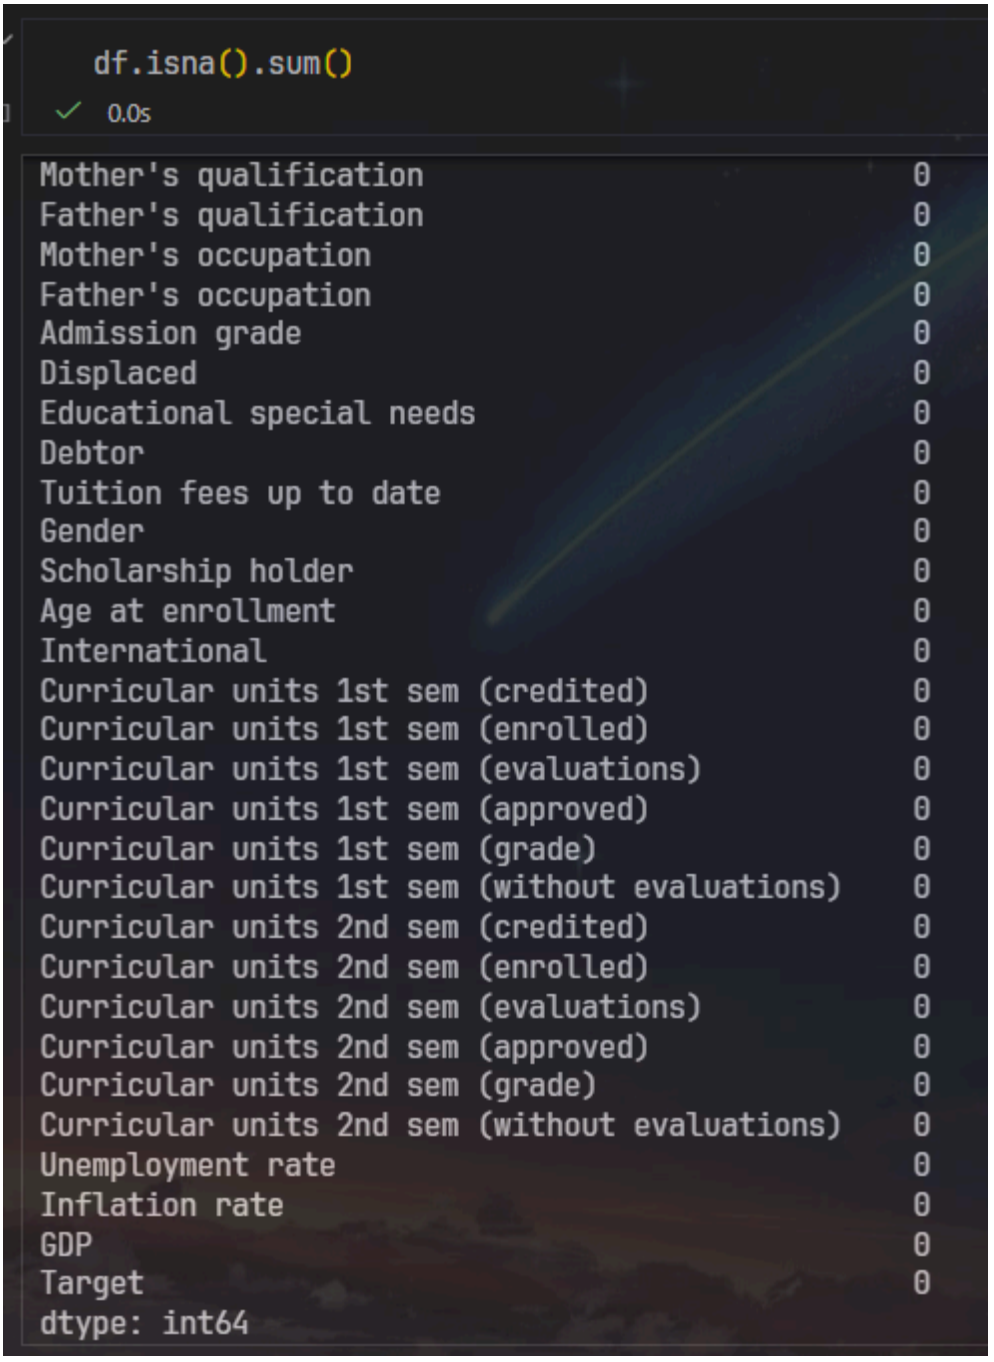

Gambar 4.1. Pengecekan *missing data*

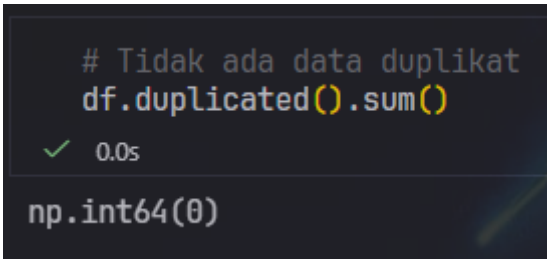

Gambar 4.2. Pengecekan *duplicate data*

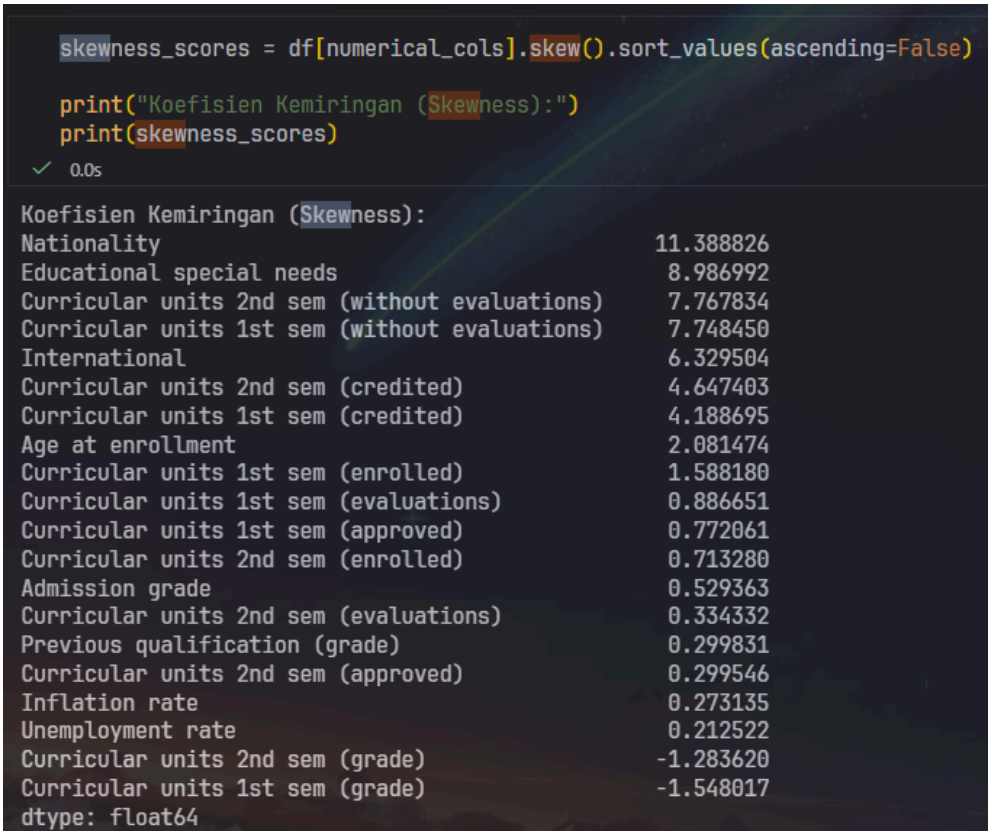

Gambar 4.3. *Skewness* tiap kolom

Selanjutnya, dilakukan *feature engineering* dengan menambahkan fitur-fitur yang informatif dan relevan. Berikut adalah fitur yang ditambahkan beserta alasannya

Nama Fitur	Deskripsi	Alasan
Success_Rate_1st_Sem	Rasio sks lulus dibanding jumlah ujian	Semakin tinggi maka semakin pintar siswa dalam mengerjakan ujian (karena banyak lulusnya)
Load_vs_Credit_1st_Sem	Rasio sks kredit dibanding jumlah sks yang diambil	Semakin tinggi maka sks yang diambil kebanyakan merupakan sks kredit sehingga mengurangi beban siswa

Grade_Improvement	Selisih nilai semester 2 dengan semester 1	Menunjukkan peningkatan/penurunan nilai yang akan condong ke graduate/dropout

Setelah itu, dimulai tahap preprocessing yang dilakukan dengan kode berikut

```python
cols_to_drop = [
    'Educational special needs',
    'International',
    'Nationality',
]

numerical_cols = [
    'Previous qualification (grade)',
    'Admission grade',
    'Curricular units 1st sem (grade)',
    'Curricular units 2nd sem (grade)',
    'Age at enrollment',
    'Curricular units 1st sem (credited)',
    'Curricular units 1st sem (enrolled)',
    'Curricular units 1st sem (evaluations)',
    'Curricular units 1st sem (approved)',
    'Curricular units 1st sem (without evaluations)',
    'Curricular units 2nd sem (credited)',
    'Curricular units 2nd sem (enrolled)',
    'Curricular units 2nd sem (evaluations)',
    'Curricular units 2nd sem (approved)',
    'Curricular units 2nd sem (without evaluations)',
    'Unemployment rate',
    'Inflation rate',
    'Success_Rate_1st_Sem',
    'Load_vs_Credit_1st_Sem',
    'Grade_Improvement',
]

log_cols = [
    'Curricular units 2nd sem (without evaluations)',
    'Curricular units 1st sem (without evaluations)',
    'Curricular units 2nd sem (credited)',
    'Curricular units 1st sem (credited)',
]

std_cols = [col for col in numerical_cols if col not in log_cols]

categorical_cols = [
    'Marital status',
    'Application mode',
    'Application order',
    'Course',
    'Mother\'s qualification',
    'Father\'s qualification',
    'Mother\'s occupation',
    'Father\'s occupation',
    'Previous qualification',
    # Kolom Biner
    'Daytime/evening attendance\t',
    'Displaced',
    'Debtor', 'Tuition fees up to date',
    'Gender',
    'Scholarship holder',
]

# Numerical pipeline
numerical_pipeline = Pipeline([
    ('scaler', StandardScaler())
])

# Categorical pipeline
categorical_pipeline = Pipeline([
    ('encoder', OneHotEncoder(drop='first', handle_unknown='ignore', sparse_output=False))
])

# Combine Pipeline
preprocessor = ColumnTransformer([
    ('log', log_scaler, log_cols),
    ('num', numerical_pipeline, numerical_cols),
    ('cat', categorical_pipeline, categorical_cols),
], remainder='drop', sparse_threshold=0) # Drop column

final_pipeline = Pipeline([
    ('preprocessor', preprocessor),
])

```

Gambar 4.4. *Preprocessing pipeline*

Tahap preprocessing dilakukan dengan menggunakan pipeline yang berbeda untuk kolom numerik dan kolom kategorikal. Pada kolom kategorikal, dilakukan *one-hot encoding* untuk menghilangkan bias ordinal terhadap data yang seharusnya nominal. Sedangkan, dilakukan *standard scaling* untuk memastikan tiap kolom memiliki rata-rata nol dan deviasi standar satu. Selain itu, ditemukan bahwa beberapa kolom memiliki kemiringan (*skewness*) yang sangat tinggi, sehingga dilakukan log-transformation untuk mengurangi kemiringan ekstrem data, menjadikannya lebih mendekati distribusi normal sebelum distandarisasi.

Selanjutnya, dilakukan teknik oversampling karena proporsi dataset tidak seimbang, di mana jumlah data yang berlabel Graduate lebih tinggi dibandingkan dengan jumlah data yang berlabel Enrolled dan Dropout. Teknik oversampling dilakukan dengan menggunakan library imblearn SMOTE

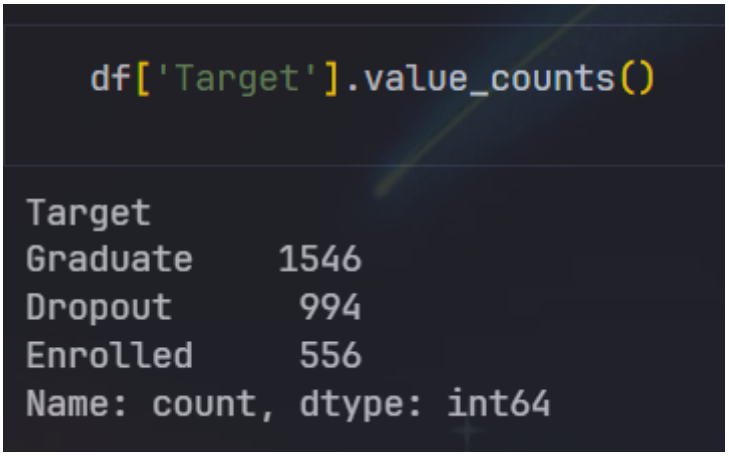

Gambar 4.5. Proporsi label data

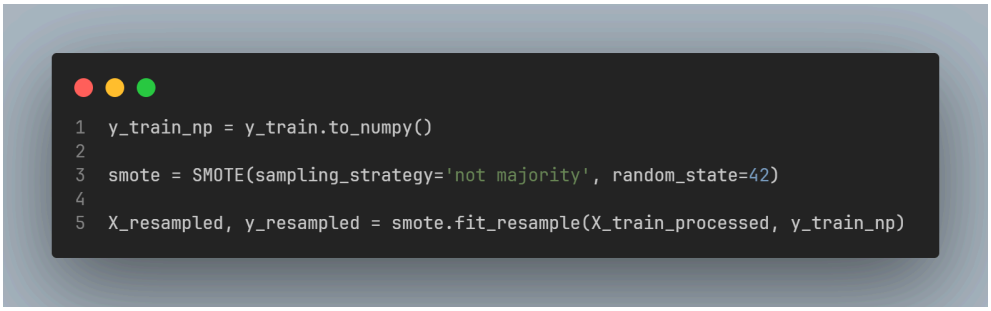

Gambar 4.6. Teknik Oversampling dengan SMOTE

5. Perbandingan Hasil

5.1. Decision Tree Learning

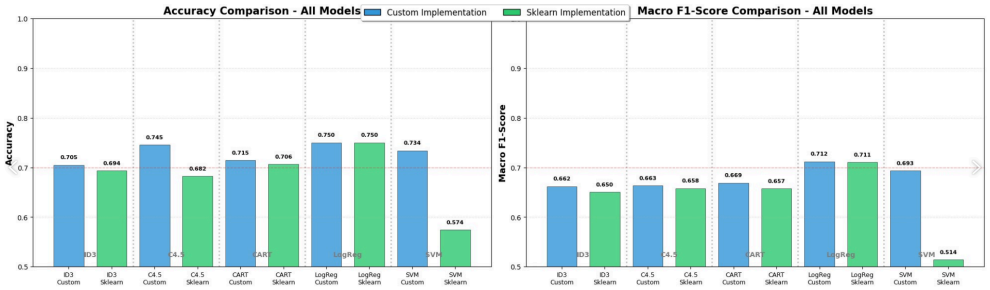

Skor	Custom Implementaton ID3	Sklearn Implementation
Accuracy:	0.7048	0.6935
Macro F1:	0.6620	0.6501

Skor	C4.5 Custom Implementation	Sklearn Implementation
Accuracy:	0.7419	0.6935
Macro F1:	0.6598	0.6501

Skor	CART Custom Implementation	Sklearn Implementation
Accuracy:	0.7145	0.7065
Macro F1:	0.6690	0.6573

Model Custom Decision Tree menunjukkan performa yang lebih baik (terutama C4.5) dibandingkan implementasi Sklearn standar karena Algoritma C4.5 menggunakan metrik Gain Ratio (Rasio Perolehan Informasi), yang secara efektif mengoreksi bias terhadap fitur dengan nilai unik yang banyak, sehingga menghasilkan pemisahan yang lebih relevan dan pohon yang lebih kuat pada data validasi. Selain itu, implementasi kustom menangani sampel dengan nilai hilang (jika ada) dengan menugaskannya ke cabang mayoritas (majority branch), sebuah heuristik spesifik yang mungkin lebih optimal untuk struktur data dan kelas minoritas di dataset akademik

5.2. Logistic Regression

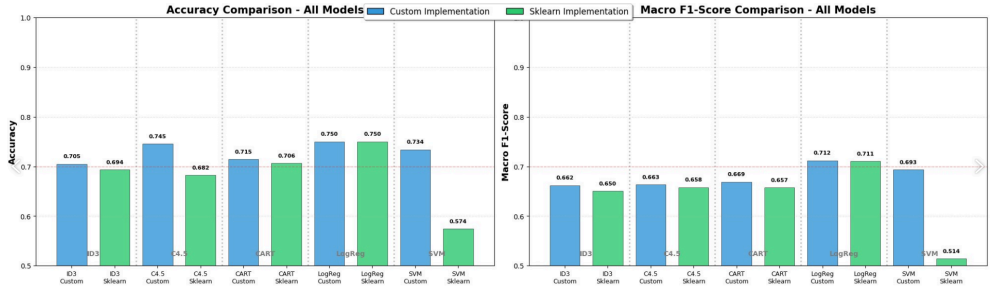

Skor	Custom Implementation	Sklearn Implementation
Accuracy:	0.7500	0.7500
Macro F1:	0.7121	0.7105
Precision:	0.7135	0.7110
Recall:	0.7219	0.7203

Perbandingan hasil menunjukkan bahwa implementasi logistic regression from scratch dan versi sklearn memberikan performa yang hampir identik pada data validasi. Akurasi kedua model sama, sementara perbedaan pada metrik F1, precision, dan recall sangat kecil dan tidak signifikan secara praktis. Hal ini mengindikasikan bahwa algoritma yang dibuat dari scratch telah berhasil mereplikasi perilaku

model sklearn dengan baik, baik dalam proses pembelajaran maupun kemampuan generalisasi. Dengan demikian, implementasi kustom dapat dianggap valid dan konsisten terhadap standar library yang sudah teruji.

5.3. SVM

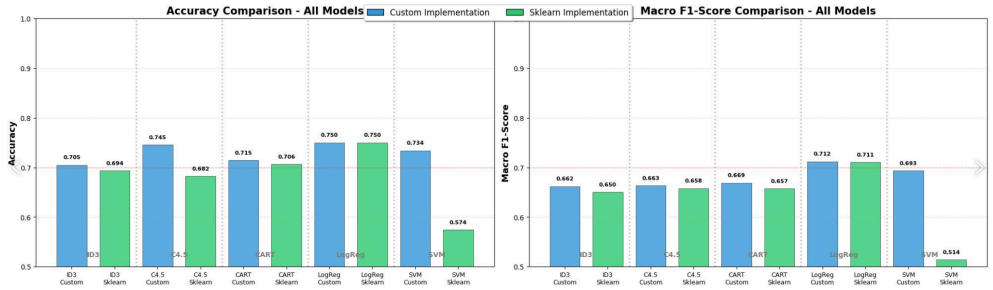

	Custom Implementation	Sklearn Implementation
Accuracy:	0.7339	0.5742
Macro F1:	0.6931	0.5144
Precision:	0.4014	0.5177
Recall:	0.6998	0.5161

SVM custom menambahkan perhitungan dengan weight dan bias menggunakan gradient descent ketika terdapat margin <1. SVM pada sklearn menggunakan one-vs-one sedangkan pada SVM custom menggunakan one-vs-all sehingga SVM custom dapat membuat hyperplane dengan pola dominan pada data tersebut. Namun, hal itu memiliki kelemahan yaitu kurang stabil.

6. Kontribusi

NIM	Nama	Kontribusi
13523128	Andi Farhan Hidayat	Model Optimization &

		Comparison
13523135	Ahmad Syafiq	Data Preprocessing & Cleaning
13523145	Andri Nurdianto	SVM
13523146	Rafael Marchel D. W.	DTL
13523152	M. Kinan Arkansyaddad	Logistic Regression

7. Referensi

Jurafsky, D., & Martin, J. H. (2025). Speech and Language Processing (3rd ed. draft). Chapter 4: Logistic Regression and Text Classification. Diakses dari https://web.stanford.edu/~jurafsky/slp3/4.pdf

Rifkin, R., & Klautau, A. (2004). In defense of one-vs-all classification. Journal of Machine Learning Research. Diakses dari https://www.jmlr.org/papers/volume5/rifkin04a/rifkin04a.pdf

Blester125. (n.d.). *Building a Numerically Stable Softmax*. Diakses dari https://blester125.com/blog/softmax.html

Martin, Eric (2025) . Multiclass Classification Using Support Vector Machines. Diakses dari https://www.baeldung.com/cs/svm-multiclass-classification

Deliverables:

- Folder **src**, digunakan untuk menyimpan source code
- Folder **doc,** digunakan untuk menyimpan laporan dalam bentuk **.pdf** yang terdiri atas komponen berikut:
  - Cover
  - Penjelasan singkat implementasi Decision Tree Learning.
  - Penjelasan singkat implementasi Logistic Regression.
  - Penjelasan singkat implementasi SVM.
  - Penjelasan tahap cleaning dan preprocessing yang dilakukan beserta dengan alasannya.
  - Perbandingan hasil prediksi dari algoritma yang diimplementasikan dengan hasil yang didapatkan dengan menggunakan pustaka. Jelaskan insight yang kalian dapatkan dari perbandingan tersebut.
    - Perbandingan hasil dapat menggunakan metrics yang sesuai dengan permasalahan yang ada.

  - Kontribusi setiap anggota dalam kelompok.
  - Referensi
- **README.md**, yang berisi deskripsi singkat repository, cara setup dan run program, dan pembagian tugas tiap anggota kelompok.